科研任务中的 AI 协作与执行

同样是“整理一份申报书”，讨论内容与处理文件需要不同的工作安排。

任务环节	具体工作	可以检查的结果
理解要求	读指南，找出章节、限制与提交要求	要求清单及原文位置
组织内容	比较研究目标、研究内容与已有依据	段落与证据的对应关系
处理文件	按模板写入正文、表格和技术路线	可打开、可编辑的文件
检查交付	核对缺项、引用、排版和版本	问题清单与修订后的文件

教学情境：本页说明任务构成，不表示已运行某个 Grant Agent 。

来源： Stanford CS224N （2026）， Lecture 10

模型、 Agent 与产品的关系

这些名称处在不同层次：有的表示能力来源，有的表示系统，有的表示工作方式。

模型	**根据输入生成判断、文字或工具调用请求。** 模型本身不等于一套完成文件任务的系统。
AI Agent	**围绕目标，结合工具和反馈推进任务的执行系统。** 具体系统的自主程度、权限和可靠性各不相同。
Agentic AI	**描述 AI 具有目标导向、多步行动等特征的工作方式。** 术语用法尚未统一，本课程按行为解释。
ChatGPT / Codex	**人们使用的产品与工作环境。** 它们可支持多种协作方式，能力也存在重叠。

判断时看实际行为：是否采取行动、读取反馈，并据此改变下一步。

来源： Stanford CS224N （2026）， Lecture 10； OpenAI Docs： Use ChatGPT

Agentic AI 与 AI Agent

前者便于描述任务怎样推进，后者便于讨论由什么系统承担执行。

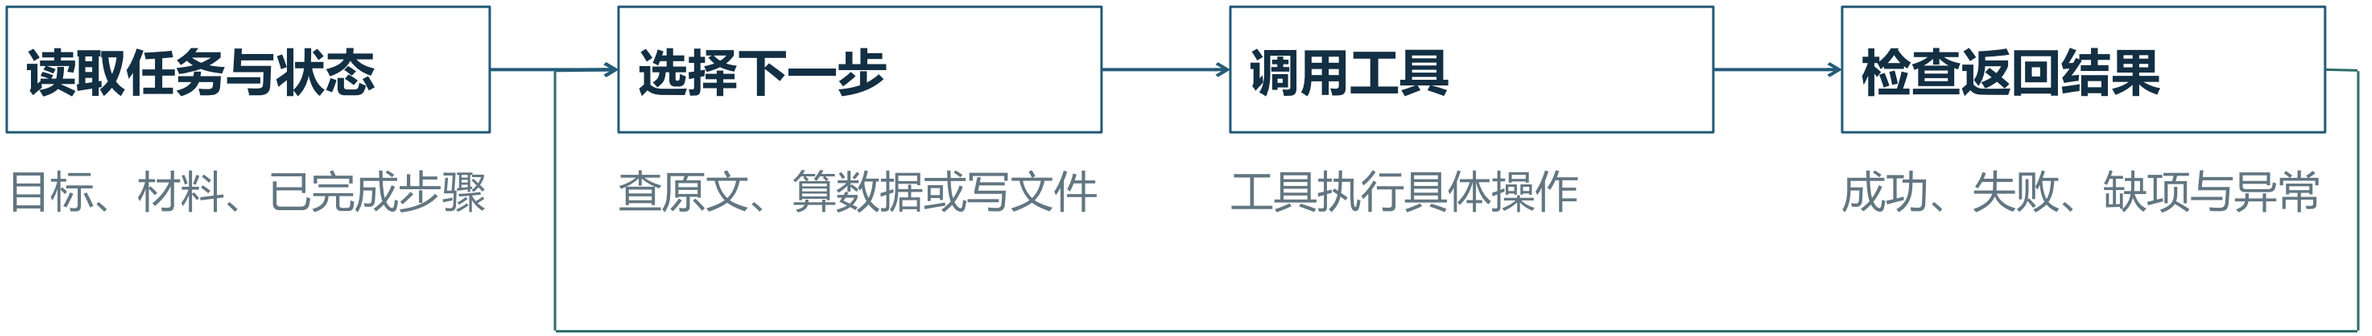
比较维度	Agentic AI： 工作方式	AI Agent： 执行系统
讨论对象	主动拆分任务、调用工具、依据反馈调整	模型、工具、状态与运行安排组成的系统
科研例子	发现引文缺少 DOI 后，继续查出版页面	负责查找引文并输出核对表的文献核验 Agent
需要追问	哪些步骤由系统决定？何时由人确认？	连接哪些工具？材料保存在哪里？如何停止？
使用限制	是一组特征，没有统一的自主程度门槛	名称本身不能证明已执行、正确或可靠

同一个 Agent 可以在固定流程与灵活判断之间切换。

来源： Stanford CS224N （2026）， Lecture 10； Anthropic： Building effective agents

Agent 怎样依据反馈继续工作

一次工具调用会产生新信息；系统应读取实际返回结果，再决定继续、改换办法或停止。



查到原文 核对题名、作者、年份和结论所处位置。

没有查到 记录检索范围与缺项；保留“尚未核实”。

遇到异常 判断是否重试、换来源，或交给研究者处理。

框架示意：箭头表示任务推进与反馈，不展示模型的内部思维过程。

来源： Stanford CS224N （2026）， Lecture 10； Anthropic： Building effective agents

固定工作流与动态决策

步骤稳定的任务适合预设流程；材料不完整、路径难以预先列出的任务需要更多动态判断。

比较维度	Workflow： 预设工作流	Agent： 动态决定部分步骤
下一步怎样确定	按事先规定的规则和顺序执行	结合当前材料与工具返回结果选择
科研情境	指南提取→字段检查→模板填入→导出	某项要求含糊，补查附件或历年说明
容易出现的问题	输入不符合预期时，流程可能卡住	可能绕远路、重复搜索或误判完成
控制办法	检查输入，设置分支与缺项提示	限定范围，保留记录，明确停止条件

组合方式：主流程固定，把证据补查等不确定环节交给 Agent 。

来源： Anthropic： Building effective agents

ChatGPT 与 Codex 的使用侧重

两者能力有重叠。选择时应看材料、工具和交付方式是否适合当前任务。

比较维度	ChatGPT 中的协作	Codex 中的协作
典型工作入口	问题、资料、文件与自然语言任务	工作目录、文件与自然语言任务
适合关注的内容	解释、比较、讨论，以及可用工具支持的产物	文件处理、脚本运行、版本记录及结果检查
都可能完成	在相应工具可用时开展研究、分析和文件制作	在相应工具可用时开展研究、分析和文件制作
使用前核对	当前账户、模式、连接工具和文件权限	当前环境、依赖、网络及文件权限

产品功能以当前环境为准；“聊天界面”也可能承载 Agent 任务。

来源： OpenAI Docs： Use ChatGPT

工具调用与执行证据

模型可以提出操作；工具实际执行后，才会有可检查的返回结果。

工具类型	实际执行什么	应保留的证据
检索工具	查询数据库或网页，读取材料	查询条件、来源链接、读取日期
计算工具	按脚本处理数据与生成统计量	数据版本、代码、运行输出
文档工具	写入 Word 、表格或幻灯片	输出文件、预览及结构检查
连接工具	读取或修改获准连接的外部系统	操作对象、返回状态和变更记录

“已完成”应能对应到真实文件或操作记录；生成一段描述不等于执行。

来源： Stanford CS224N （2026）， Lecture 10； OpenAI Docs： Architecture

Skill： 可复用的任务做法

Skill 把一类任务的处理要求、参考材料和必要脚本放在一起，供 Agent 按需使用。

何时使用	描述适用任务，例如“核验参考文献”。
怎样处理	规定先查原文、再核对字段，并登记未核实项。
依据什么	附上规范、字段说明、模板或检查清单。
怎样交付	规定结果表的字段、文件格式和缺项说明。

文献核验 Skill 的课程示例

输入
参考文献列表及已有 DOI

过程
查出版记录，逐项比对

输出
已核实、存在差异、
尚未核实的记录

只有 SKILL.md，也可以是指令型技能；能否执行还取决于工具、资源和环境。

来源： OpenAI Docs： Build skills

Prompt 、 Skill 、工具与 MCP

它们分别处理任务要求、可复用方法、具体操作和连接方式。

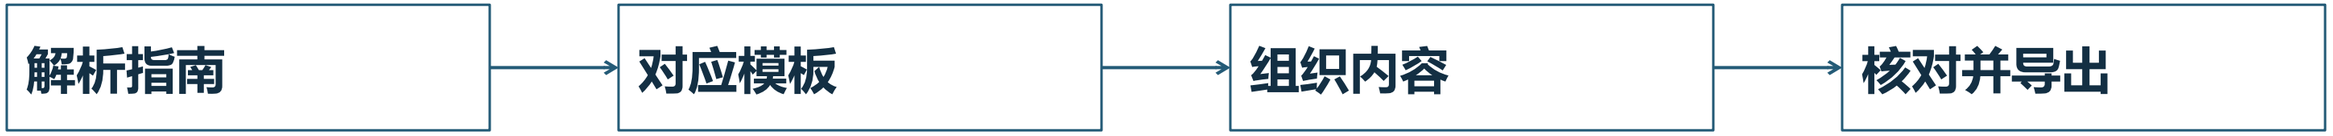
名称	主要作用	文献核验中的例子
Prompt： 提示	说明这一次要做什么、有哪些限制	核验本次列表，保留未核实项
Skill： 任务方法	保存可重复采用的步骤与资源	题名、作者、年份、 DOI 逐项比对
Tool： 工具	执行某个具体操作	查询记录、读取 PDF 、导出表格
MCP： 连接标准	让应用按共同约定连接外部工具或数据	通过支持 MCP 的服务访问获准数据源

MCP 不赋予数据库访问资格； Skill 也不能替代工具权限或真实材料。

来源： OpenAI Docs： Build skills ； MCP 官方： What is MCP?

申报材料处理的工作流框架

把每一步的输入、输出和检查条件写清楚，才能判断文件是在推进，还是只生成了更多文字。



保留条款与原文位置　　章节、字段、字数与附件　　只使用已提供的研究依据　　检查缺项、引用及文件

指南要求　要能追到具体章节、附件或原文条款。

研究内容　要区分已有结果、拟开展工作与缺少的材料。

最终文件　应保留可编辑正文、问题清单和版本信息。

教学框架：完整 Grant Agent 的实际材料、操作与运行结果在 Section 10 展示。

来源： Anthropic： Building effective agents

多 Agent 协作的适用范围

多个角色有助于分工，也会增加信息传递和结果合并的负担。

分工方式	可承担的任务	需要防止的问题
按材料分工	分别读取不同论文，再按同一字段汇总	遗漏共同标准，重复或相互矛盾
按方法分工	检索、统计与制图分别处理	输入版本不同，结果无法衔接
按检查角度分工	核对来源、论证与格式	反复评价文字，缺少原始证据
统一汇总	处理冲突，保留依据与待判断项	把多数意见当成科学结论

分工是组织选择；多个模型给出同样答案，也需要核对原始证据。

来源： Anthropic： Building effective agents； Stanford CS224N （2026）， Lecture 10

上下文、记忆与任务状态

长任务需要把关键进展保存下来，不能只依赖当前对话中的文字。

信息类型	保存什么	科研情境
当前上下文	本次可用的指令、材料与工具结果	正在核对的一篇论文及目标字段
可检索记忆	后续能够再次取用的记录或资料	已经整理的文献笔记与来源
任务状态	哪些已完成、失败或等待确认	已核对条目、未取到原文的条目
文件版本	输入和输出各自采用哪个版本	指南修订日期、数据版本、文稿版本

对话摘要有助于接续任务；重要结果仍应保留原文件与可定位出处。

来源： Stanford CS224N （2026）， Lecture 10； Anthropic： Effective harnesses （2025）

Harness ： 让 Agent 持续工作的运行安排

模型负责生成判断和操作请求； Harness 组织这些请求怎样执行、留痕、接续和停止。



材料版本、允许范围、完成条件

运行工具，接收反馈，处理异常

保存进展，核对产物，决定结束

对教师而言	可以把它理解为执行任务所需的一整套运行安排。
不同于 Skill	Skill 提供特定任务的做法； Harness 负责承载和管理执行。
需要注意	不同系统的实现和命名不同，没有一张适用于全部产品的清单。

课程框架：用于理解运行职责，不要求掌握接口、代码或部署参数。

来源： OpenAI Docs ： Architecture ； Anthropic ： Effective harnesses （ 2025 ）

Harness 中的材料与版本管理

同一个任务接着做，首先要确认接着处理的是哪份材料、哪一版要求。

管理对象	需要记录什么	缺少记录的后果
任务要求	目标、范围与完成条件	内容不断增加，迟迟无法结束
输入材料	来源、文件名、日期与版本	旧指南或错误数据混入结果
中间结果	原文位置、处理步骤与待核对项	重复查找，无法追溯结论
最终产物	对应输入版本、输出路径与检查记录	无法判断哪份文件可供使用

教学情境：指南更新后，应标记受影响的章节并重新核对，不能沿用旧的完成状态。

来源： Anthropic： Effective harnesses （2025）； OpenAI Docs： Architecture

Harness 中的工具权限与人工确认

任务可以连续推进，但读取、修改和对外提交需要分别确定允许范围。

操作范围	运行前说明	适合保留的确认点
读取材料	可读取哪些文件与外部来源	敏感资料是否允许进入相应环境
修改文件	允许写入的位置，是否保留原件	覆盖关键文件或删除材料之前
对外操作	是否允许提交、发送或发布	投稿、申报和对外发送之前
结果判断	系统可检查哪些事项	研究结论、成果归属与作者确认

本页是科研运行建议；权限细节须与学校要求、工具能力及任务授权一致。

来源： OpenAI Docs： Architecture； MCP 官方： What is MCP?

Harness 中的失败恢复与停止条件

可靠的接续需要知道失败在哪里、已经保存什么，以及重试是否会产生重复操作。

记录失败位置 → **判断能否重试** → **恢复或交接**

工具、输入版本和错误信息

权限、来源、次数与重复写入风险

继续未完成部分或交给研究者

检索未命中	可换关键词或来源；仍无依据时标记尚未核实。
文件导出失败	保留正文与错误信息；修复后重新导出并检查。
已执行但未确认	先查操作状态；不要盲目重复提交或覆盖。

达到完成条件、资源上限或人工判断点时停止，并留下清楚的交接记录。

来源： Anthropic： Effective harnesses （2025）

Agent 的完成情况怎样核验

从运行成功到科研可用，需要检查不同层次的结果。

检查层次	可以检查什么	通过后仍不能推出什么
运行与文件	工具返回、文件存在、文件能否打开	不能说明内容正确或任务完整
结构与要求	章节、字段、格式及必需附件	不能说明科学论证成立
数据与来源	计算可复核，引文和原文对应	不能自动确认研究价值与因果关系
任务与专业判断	实际要求是否完成，限定是否恰当	不能由少量示例证明所有任务可靠

演示一次成功，应报告具体输入、范围和检查项；测试结果按实际覆盖范围解释。

来源： Stanford CS224N （2026）， Lecture 10

科研任务怎样选择协作方式

先判断任务是否需要工具执行和持续记录，再决定采用多大的自动化范围。

任务特征	适合的起点	交付时重点核对
需要讨论和解释	提供材料，围绕问题进行对话	概念、出处与适用条件
步骤稳定、重复处理	规定字段与顺序，建立工作流	输入范围、缺项和输出一致性
需要边查边判断	使用工具反馈推进的 Agent	检索路径、证据与停止原因
需要跨会话持续完成	补充 Harness 的状态与恢复安排	版本、进展、权限与可用产物

后续课程：按科研任务展开； Section 10 看申报流程， Section 14 看真实运行与接续。

来源： Anthropic： Building effective agents； OpenAI Docs： Architecture