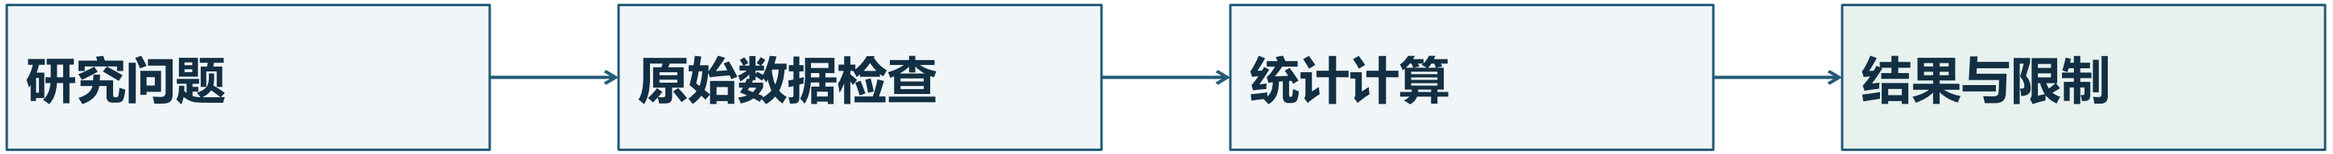
数据处理与统计分析

本节用公开测量数据，说明检查、计算和解释怎样衔接。



同物种雌雄鳍长差异

核对字段、单位与缺失

描述分布并估计差异

说明假设与适用范围

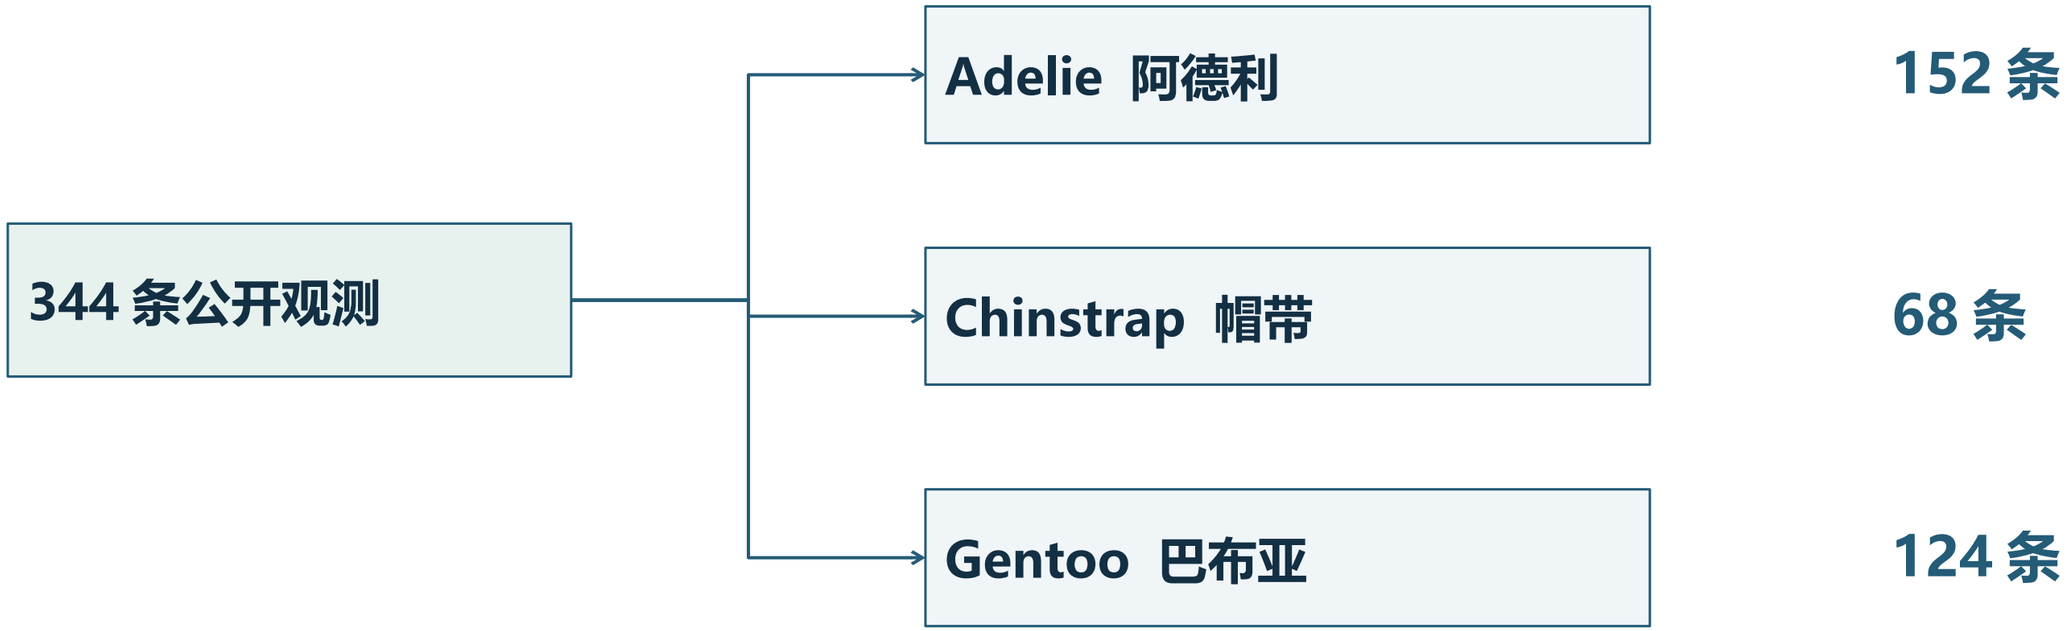
示例任务：比较同一物种的雌雄鳍长，并核对年份、缺失与独立性假设。

分析对象、单位和排除规则共同决定结果含义。

来源： UC Berkeley 2026， EDA I， pp.9/20/24

公开数据的采集背景

Palmer 数据包含 344 只企鹅、 3 个物种、 3 座岛屿，采集年份为 2007—2009 。



3 座岛屿， 2007—2009 年

公开观测数据的二次教学分析，研究范围需结合原始采样设计判断。

来源： palmerpenguins 公开数据，本课程二次计算

原始表格中的数值与缺失

预览前 6 条记录，就能看见鳍长的单位、性别分类，以及整组测量缺失。

CSV 行	物种	鳍长 mm	性别	年份
2	Adelie	181	male	2007
3	Adelie	186	female	2007
4	Adelie	195	female	2007
5	Adelie	NA	NA	2007
6	Adelie	193	female	2007
7	Adelie	190	male	2007

NA 表示缺失； male 为雄、 female 为雌。 CSV 行号仅用于追溯。

来源： palmerpenguins 公开数据，本课程二次计算

字段定义与比较口径

示例问题限定为 Adelie 物种内部的雌雄鳍长比较，测量单位保留毫米。

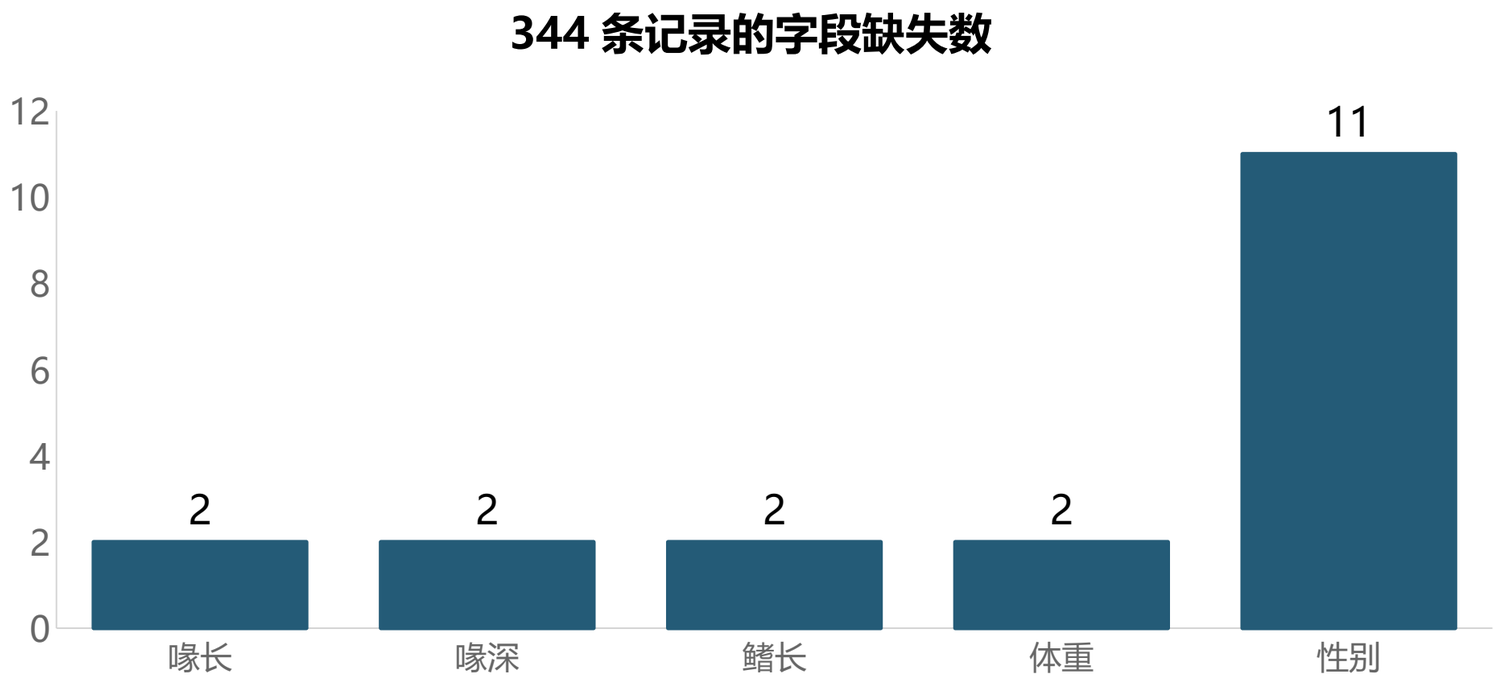
字段	含义与单位	本次用途
species	物种，分类	限定 Adelie
sex	female （雌） / male （雄）	分组变量
flipper_length_mm	鳍长，毫米	连续结果变量
island / year	岛屿 / 采集年份	检查组成与分层
原始个体 ID	简化表未提供	无法仅凭此表核验依赖关系

本节计算沿用原始字段，不对 NA 补零或猜测性别。

来源： palmerpenguins 公开数据，本课程二次计算

缺失检查与分析分母

344 条记录中，性别缺失 11 条，四个体型测量字段各缺失 2 条。



分析分母随问题改变

物种、岛屿、年份
均无缺失。

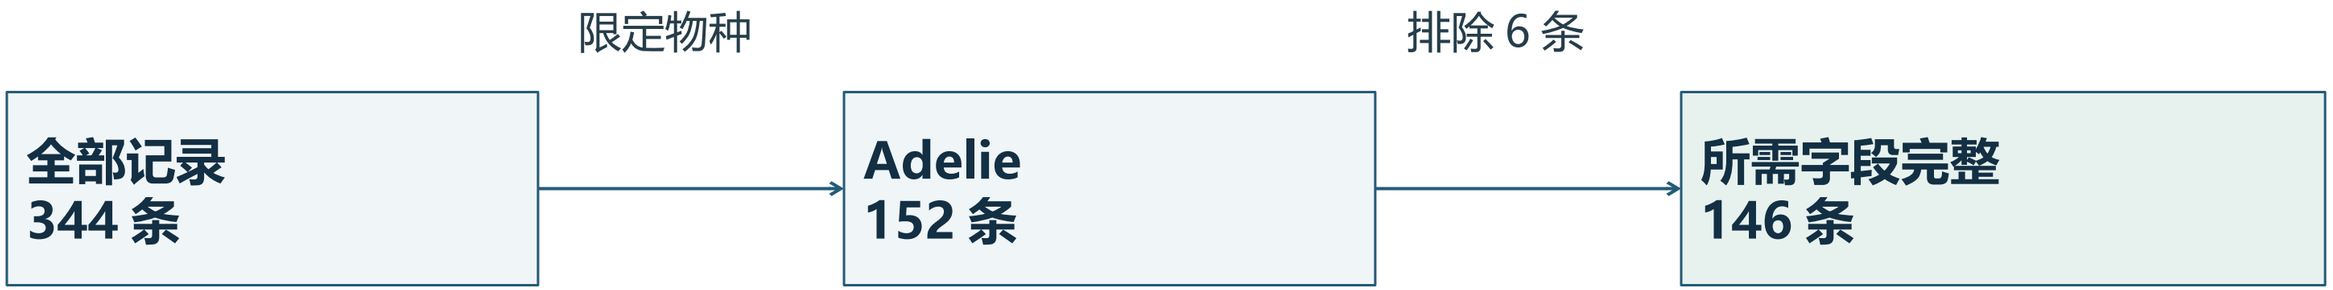
同一条记录可能
缺少多个字段。

每个字段的缺失数有重叠，须回到行记录确定排除范围。

来源： palmerpenguins 公开数据，本课程二次计算

本次计算的纳入流程

152 条 Adelie 记录中， 6 条缺少性别或鳍长，最终纳入 146 条。



male： 73 条
female： 73 条

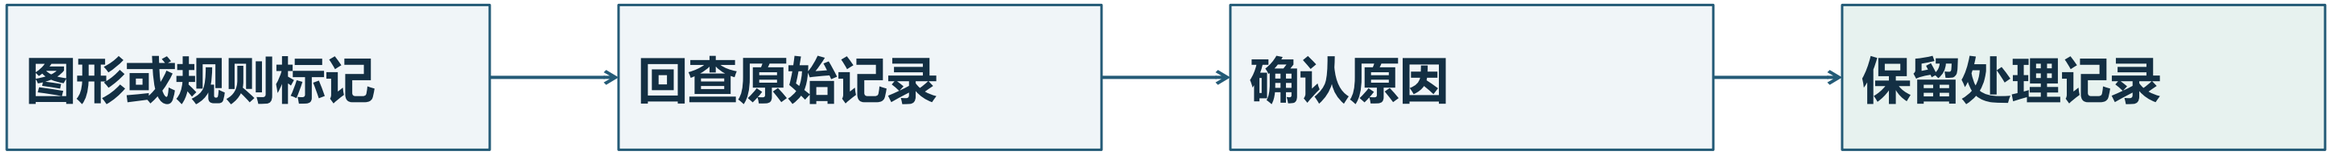
排除依据：性别或鳍长缺失
未进行插补，完整记录分析仍可能受缺失机制影响。

仅检查本次所需列；缺失处理的影响仍须结合采样记录判断。

来源： palmerpenguins 公开数据，本课程二次计算

异常值的复核流程

远离多数观测的值需要查原因，删除和修正都要保留依据。



辨认需要核查的观测

核对单位与测量过程

错误修正或合理保留

必要时做敏感性分析

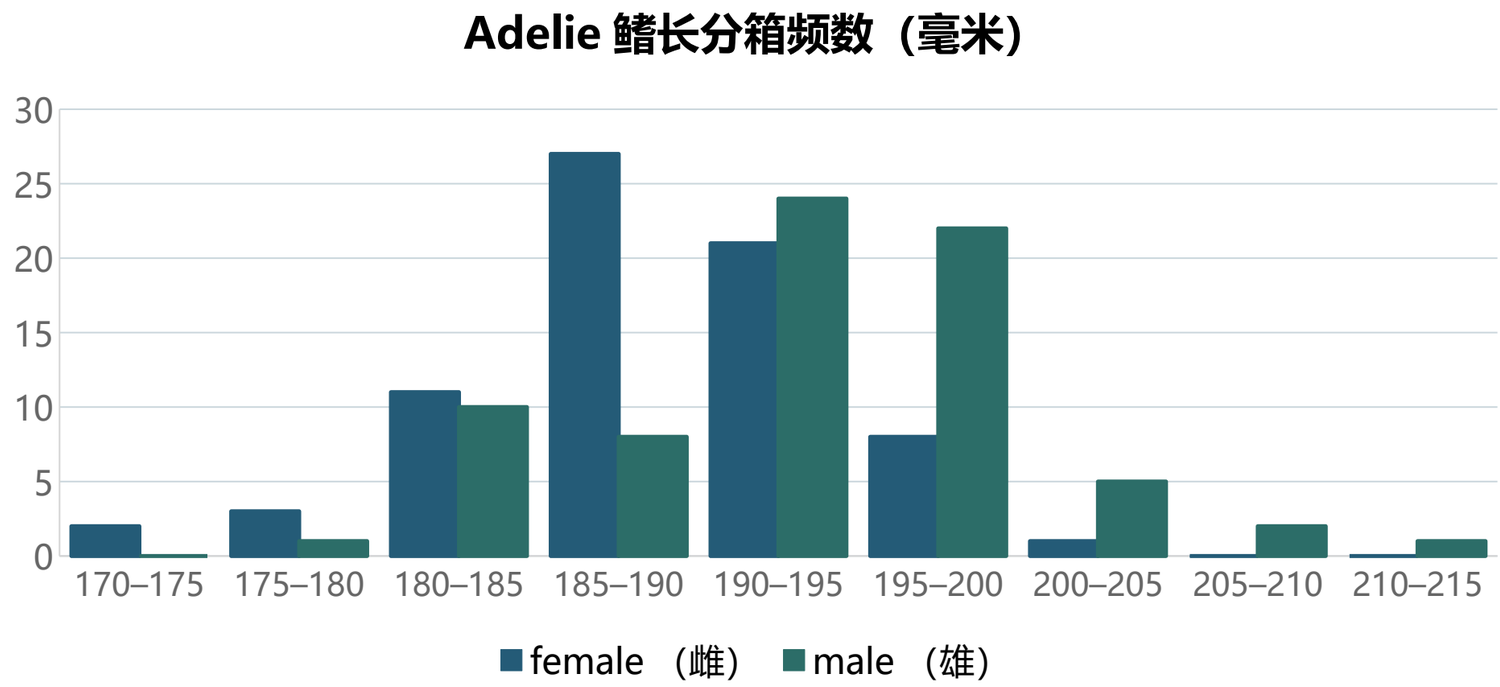
筛查只产生待核查记录。确认错误、修正及排除，都需说明依据。

按分布范围筛查标记 2 条，移除 0 条；异常原因仍需原记录复核。

来源： NIST 统计手册 §1.3.5.17

鳍长分布与组间重叠

雌雄分布有重叠，均值差异不能用于准确判断每一只企鹅的性别。



每组 73 条

每 5 毫米一组

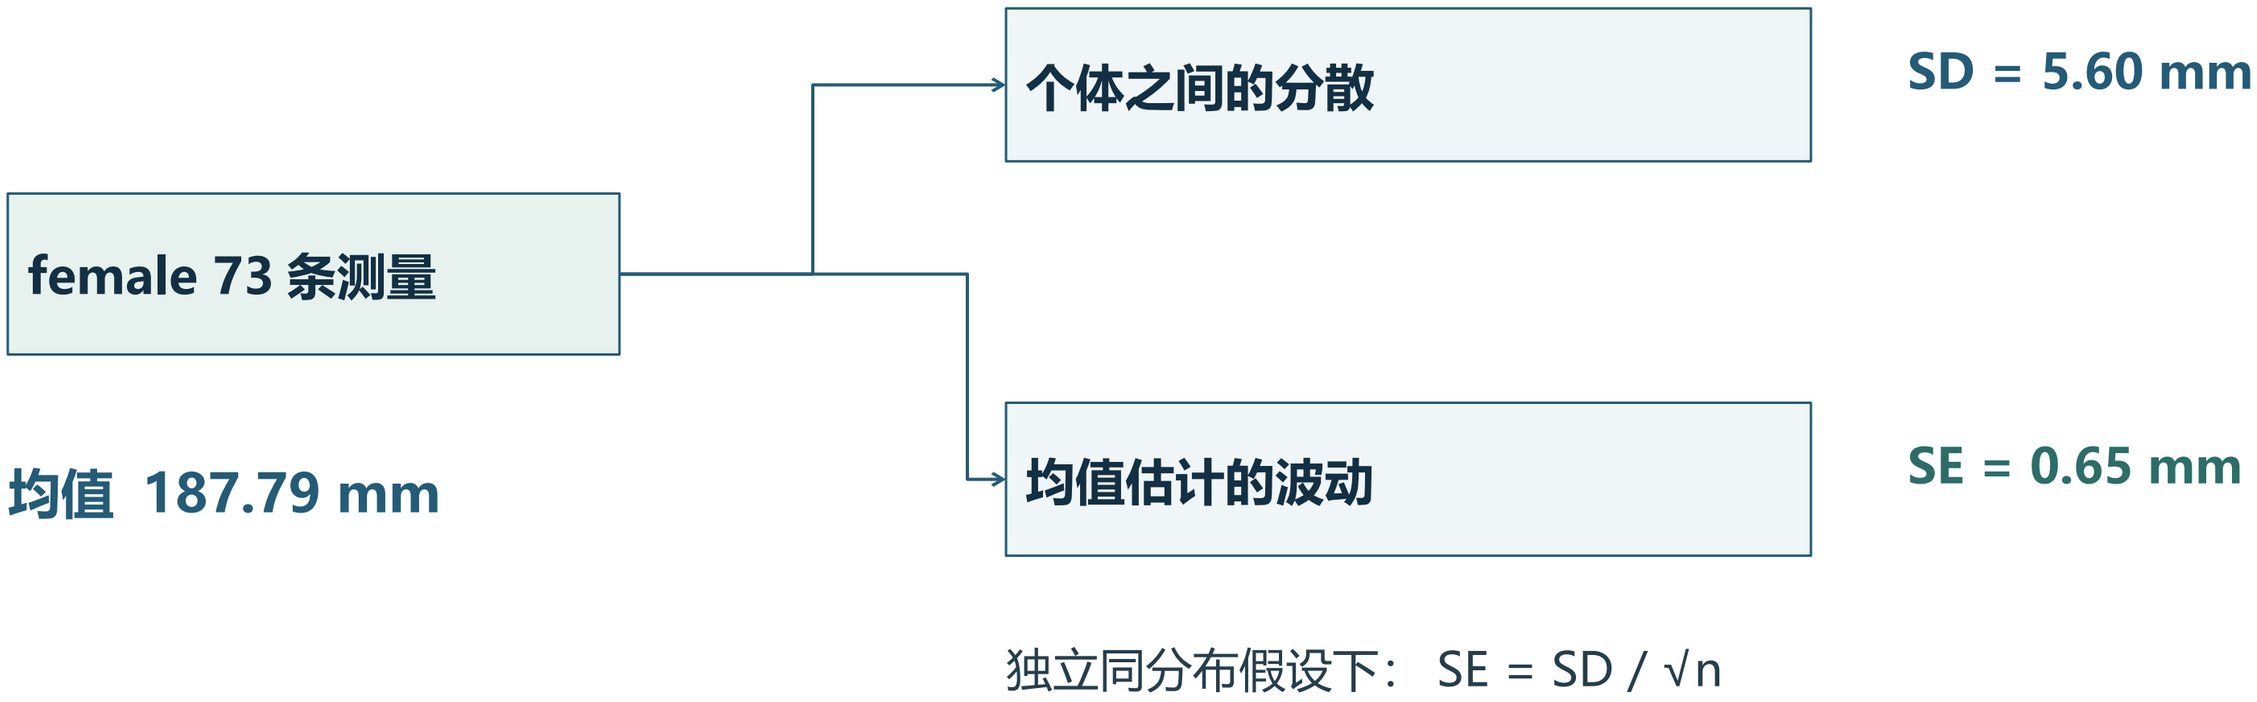
组间有重叠，
均值差异不等于
个体可准确分类。

横轴为鳍长区间，纵轴为记录数。分箱边界与计数可复算。

来源： palmerpenguins 公开数据，本课程二次计算

标准差与标准误

标准差描述个体测量的分散程度，标准误描述均值估计在抽样中的波动。



独立同分布假设下： $SE = SD / \sqrt{n}$

此处 SE 以行独立为假设，未核验巢或个体层面的相关结构。

来源： NIST 统计手册 §1.3.5.2； palmerpenguins 公开数据，本课程二次计算

独立组与配对数据

不同个体组成的两组，与同一个体在两个时点的记录，具有不同的数据结构。

独立组示意

个体 A 、 B 、 C
组 1

个体 D 、 E 、 F
组 2

比较两组的分布或均值

配对示意

同一个体 X
时点 1

→

同一个体 X
时点 2

先计算每个个体的前后差

教学结构示意。组内行数相等不能证明一一配对。

来源： NIST 统计手册 §1.3.5.3 ； 课程方法示意 / 教学模拟

分析方法与数据结构

方法选择需要同时考虑结果类型、研究问题、分配或采样单位及模型假设。



重复测量、聚类或多组比较，需进一步匹配研究设计。

本节实际运行描述统计与分组重抽样（bootstrap），未运行所有分支。

来源： NIST 统计手册 §1.3.5.3； 课程方法示意 / 教学模拟

雌雄均值差与条件区间

Adelie 完整记录中，雄性均值比雌性高 4.62 毫米。

完整记录	n	均值 mm	SD mm
female （雌）	73	187.79	5.60
male （雄）	73	192.41	6.60

雄减雌： 4.62 mm

重抽样区间： 2.68—6.58 mm

每组按行抽样， 10000 次，取 2.5% 与 97.5% 分位点。

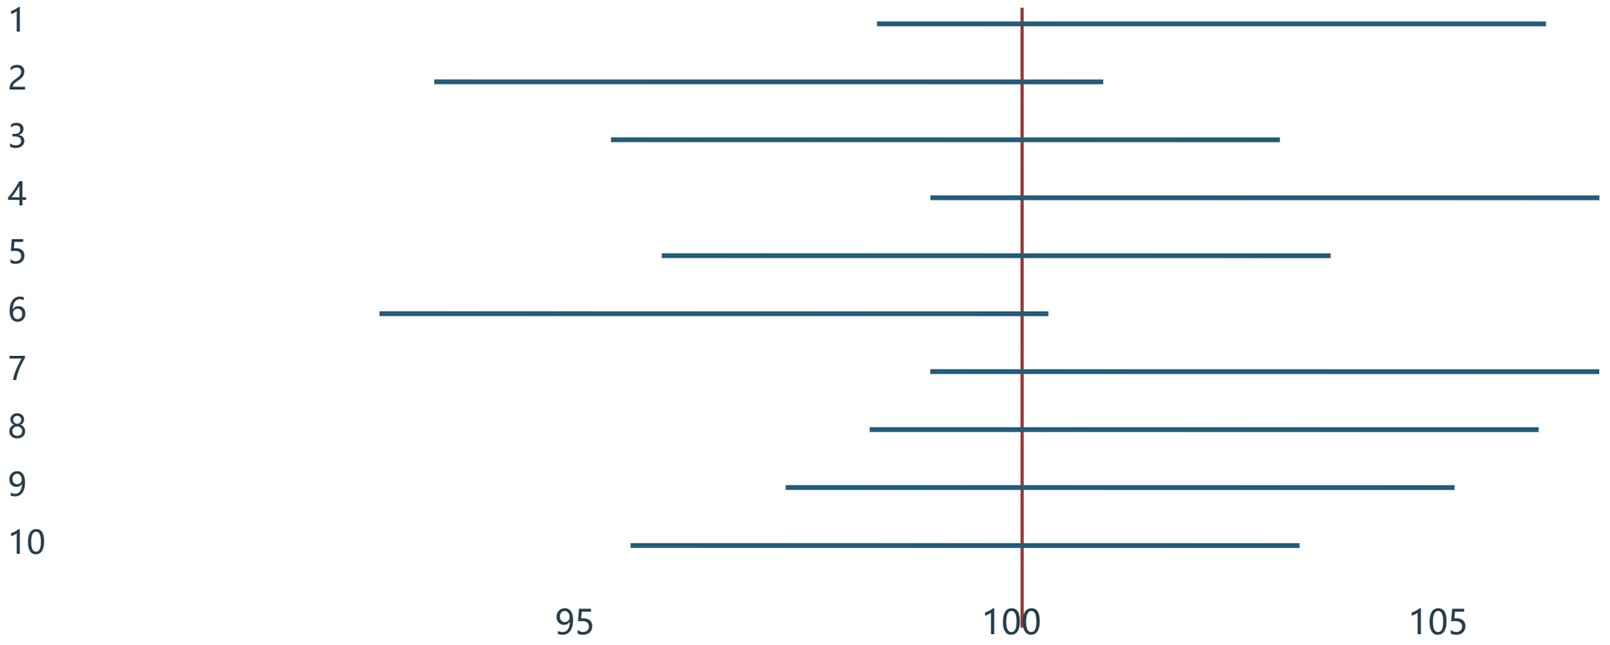
区间依赖行独立假设，不是原研究的已发表推断结论。

来源： palmerpenguins 公开数据，本课程二次计算； UC Berkeley 2026 ，置信区间， pp.4/7/8

95% 置信水平的重复抽样含义

如果反复按同样规则抽样并构造区间，约 95% 的区间会包含那个固定真值。

同一真值： 100



横线为各次区间（显示前 10 次）

独立正态模型

设定均值 100
已知 SD=10
每次 n=25

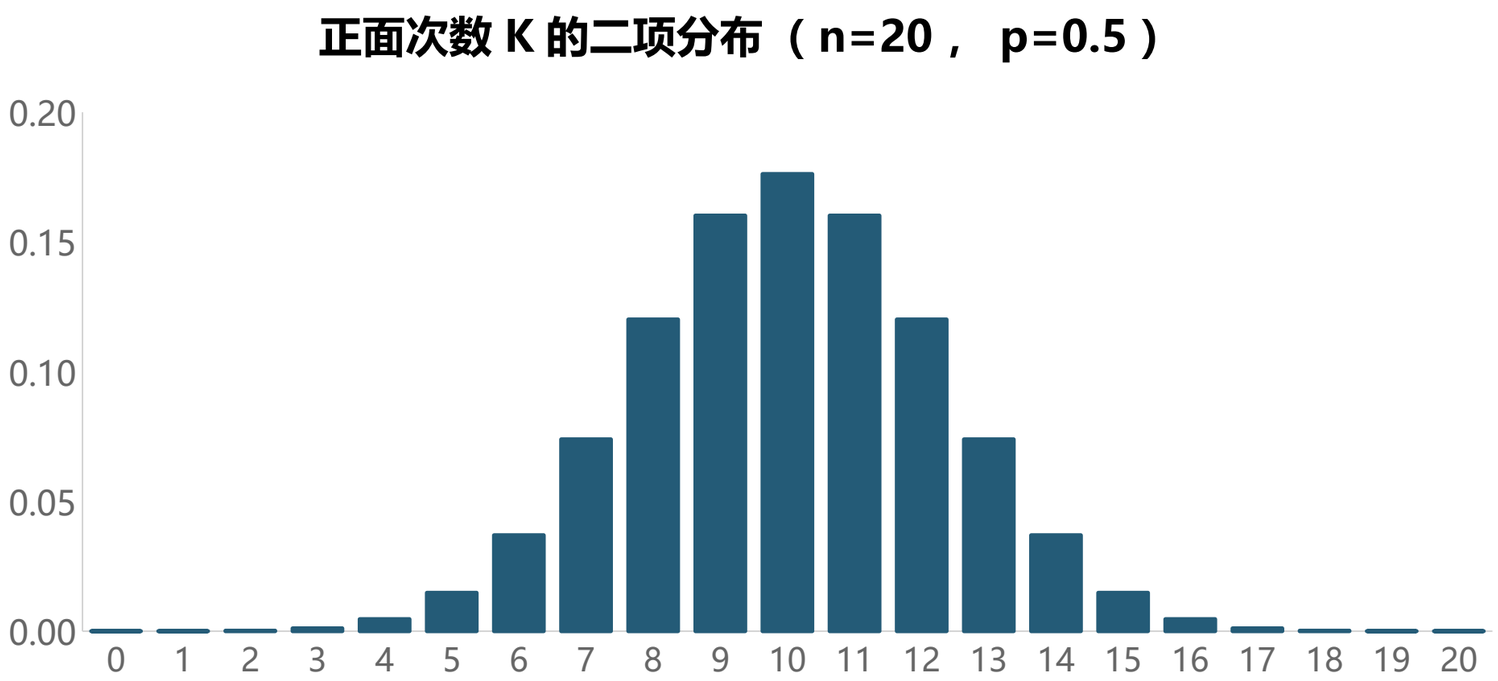
1000 次中
941 次覆盖真值

正态模型教学模拟，参数自设； 1000 次结果及前 10 次区间均保留 CSV 。

来源： UC Berkeley 2026 ， 置信区间， pp.4/7/8 ； NIST 统计手册 §1.3.5.2 ； 课程方法示意 / 教学模拟

双侧 P 值的条件含义

教学设定：独立抛硬币 20 次，观察到 15 次正面，在正反等可能假设下计算两端概率。



双侧极端事件

K ≤ 5 或 K ≥ 15

两端概率之和
P ≈ 0.0414

不表示零假设
为真的概率。

教学设定，不是企鹅检验。精确双侧 P≈0.0414，未采用正态近似。

来源： UC Berkeley 2026，假设检验， pp.6/17/29； ASA， 2016， P 值声明；课程方法示意 / 教学模拟

效应大小、统计证据与科研解释

结果报告需要同时交代差异大小、估计不确定性和研究设计允许的解释范围。

差异与单位 → **估计不确定性** → **研究范围**

对象和比较方向

抽样与模型条件

选择、混杂与适用对象

企鹅的毫米差异和硬币的尾概率，分别对应不同问题与模型。

显著性阈值无法单独回答差异是否重要、研究是否可靠。

来源： ASA， 2016， P 值声明； UC Berkeley 2026，假设检验， pp.6/17/29

Bootstrap 的有放回重抽样

在每个组内重复抽取原有记录，观察均值差如何随重抽样改变。

雌、雄两组各 73 条 → **各组有放回抽样** → **计算一次均值差** → **重复 10000 次**

保留原有测量记录

每组仍取 73 条

方向固定为雄减雌

估计分位点与波动

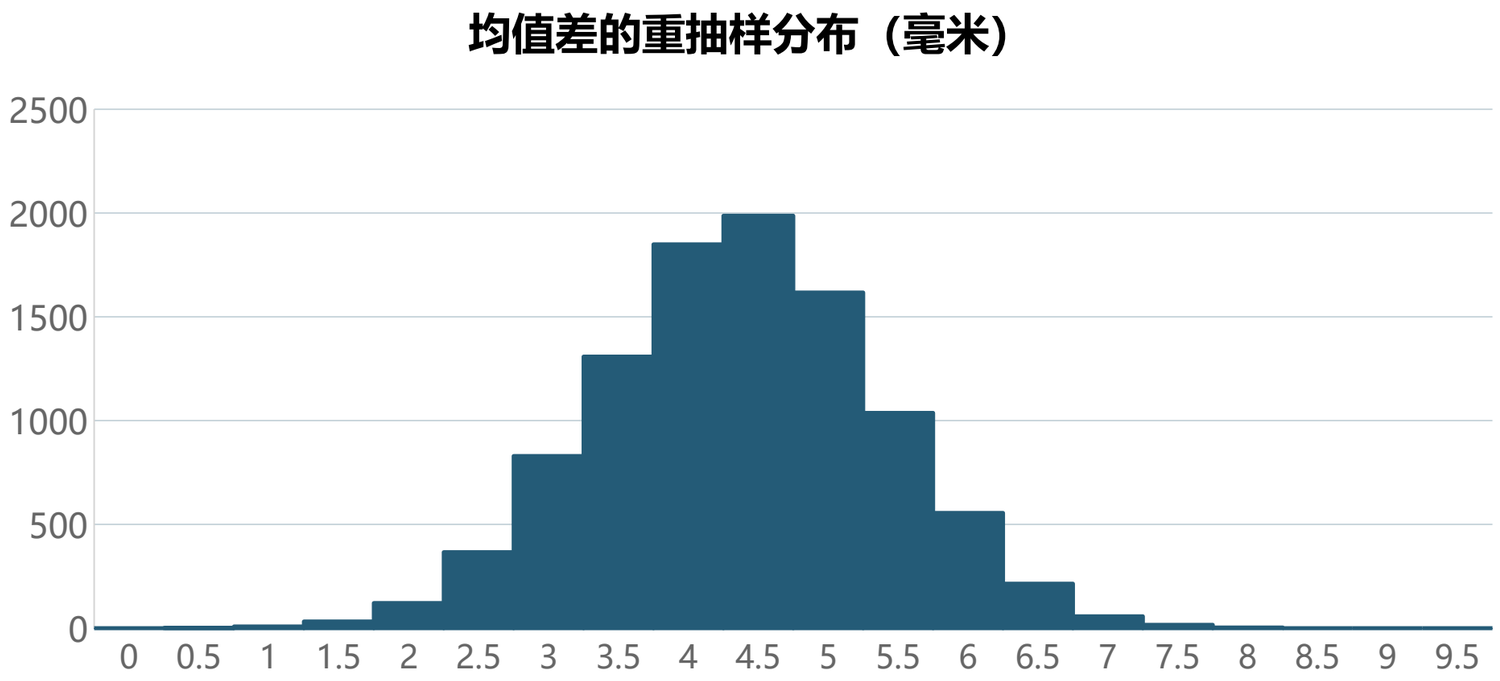
若研究以巢、班级或受试者为单位，重抽样也需保留相应结构。

这次脚本按行抽样。重抽样次数增加，不能修复原始样本的选择偏差。

来源： UC Berkeley 2026， 置信区间， pp.4/7/8； NumPy 有放回抽样文档；本地脚本实算

重抽样结果的分布

10000 次均值差的 2.5% 与 97.5% 分位点为 2.68 和 6.58 毫米。



百分位区间

每柱宽 0.5 毫米
横轴标区间左端

2.68—6.58 mm

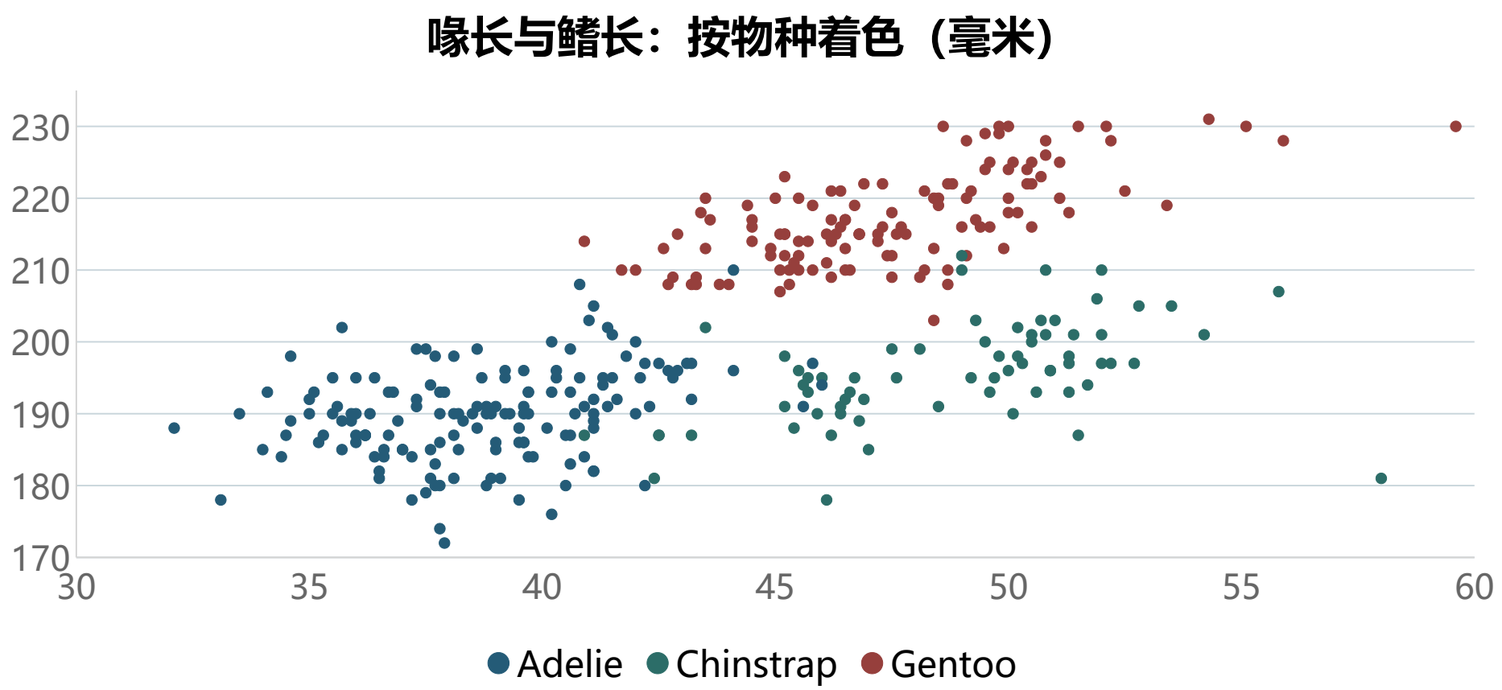
这不是个体鳍长的分布。

本地实际计算；随机种子、分位点算法与完整重抽样值均可检查。

来源： UC Berkeley 2026， 置信区间， pp.4/7/8； NumPy 有放回抽样文档；本地脚本实算； palmerpenguins 公开数据，本课程二次计算

混合物种与组内相关

把物种混在一起，喙长与鳍长的总体相关可能包含物种间差异。



Pearson 相关

总体　r = 0.656
Adelie 内　r = 0.326

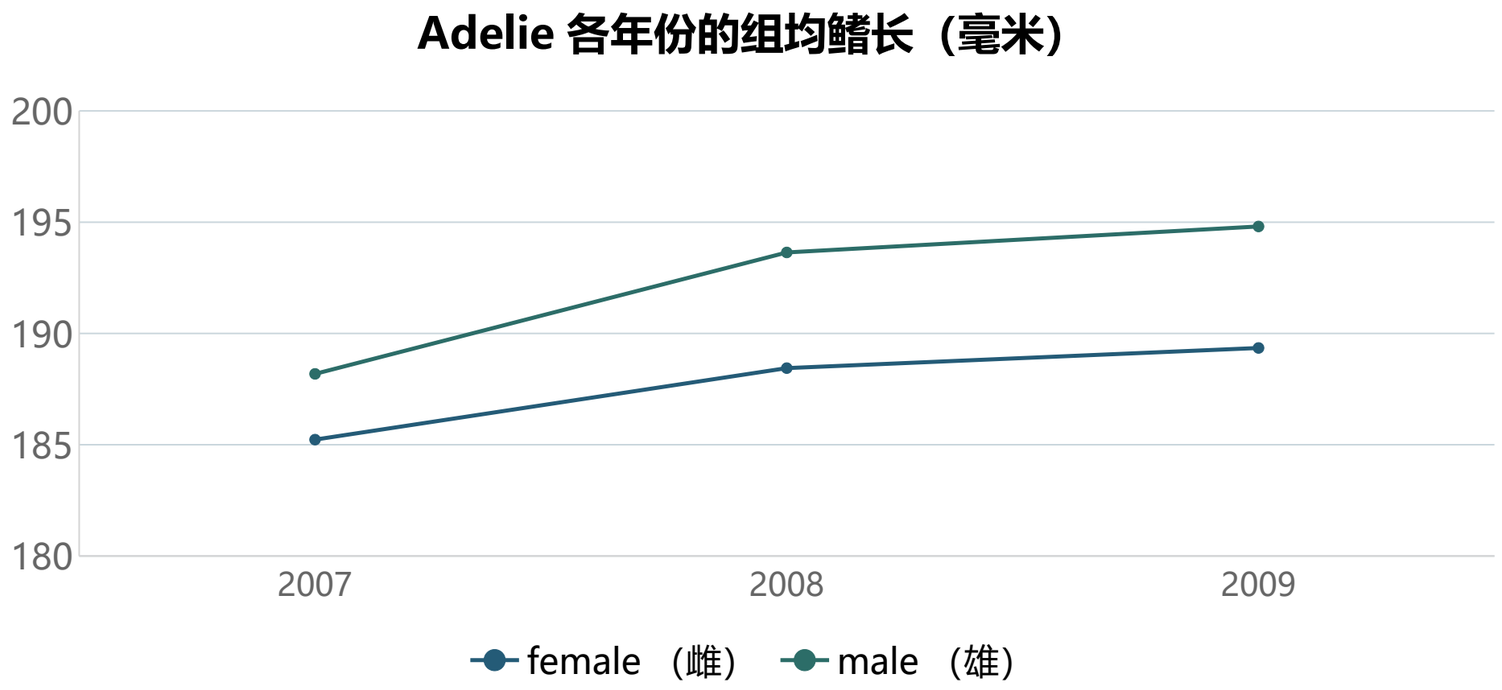
总体关系包含
物种间的差异。

横轴喙长 mm ，纵轴鳍长 mm 。点来自公开观测，未画未经计算的拟合线。

来源： palmerpenguins 公开数据，本课程二次计算

采集年份与样本组成

同为 Adelie， 2007—2009 年的均值仍有变化，合并报告需要检查组成。



各年每组记录数

2007： 22 条
2008： 25 条
2009： 26 条

各年观测的组均值，
不表示个体生长。

各年为观测记录的组均值，不是同一批个体的纵向变化。

来源： palmerpenguins 公开数据，本课程二次计算

结果段落中的对象、数字与限制

一段可检查的结果文字，需要把纳入范围、差异方向、方法和限定条件写在一起。

二次分析结果示例

在性别与鳍长均完整的 146 条 Adelie 记录中，雌雄各 73 条。雄性平均鳍长为 192.41 毫米，雌性为 187.79 毫米，均值差为 4.62 毫米。按两组分别进行 10000 次有放回重抽样，百分位区间为 2.68—6.58 毫米。

该区间依赖行独立的抽样假设。简化数据未提供可核验的巢与个体对应关系，也未在此模型中调整年份、岛屿和缺失机制，因此本例保留为条件分析，不作因果解释。

公开数据的二次教学结果，未作为原研究的结论或新科研成果发布。

来源： palmerpenguins 公开数据，本课程二次计算； ASA， 2016， P 值声明

Cursor 改代码以后，怎样确认结果

同一份企鹅数据：把鳍长均值差由“雄减雌”改为“雌减雄”，再核对两次输出。

Cursor：编辑代码 → **Python：运行脚本** → **文件：两次输出** → **复核：回到原数据**

改差值公式和字段名；
查看修改前后的差异。

使用同一个解释器，
分别执行两个脚本。

分开保存 CSV 和记录；
差值应为相反数。

纳入行、两组人数、
均值和 SD 应不变。

实际 Python 输出：同一数据、同一 146 条记录

原脚本：雄减雌

+4.616438 mm

修改后：雌减雄

−4.616438 mm

每组仍为 73 条

均值与样本 SD 不变

本例两份 Python 脚本已在本地运行； Cursor 未操作， SPSS 未执行。 R 沿用本地 WebR 实算记录。

来源： CMU 2025 Lecture23，第 26 页； Cursor Agent 与终端文档；本地 Python 改动与实算

Python 与 R 的实际结果核对

软件输出需要对照纳入行、分组、单位和计算定义，界面不同不应改变分析对象。

核对项目	Python 实际输出	R 实际输出
纳入数 / 雌雄各 n	146 / 各 73	146 / 各 73
均值 mm：雌 / 雄	187.79 / 192.41	187.79 / 192.41
样本 SD mm：雌 / 雄	5.60 / 6.60	5.60 / 6.60
雄减雌均值差 mm	4.62	4.62

逐行核对 146 条记录，再比数字。 SD 采用 n−1 分母，均值差固定为雄性减雌性。

SPSS 尚未运行；得到输出后，再核对同样的行号和统计量。

来源：本地 Python/R 实算与代码； R 官方数据输入与 SD 说明； IBM 官方语法索引，未执行