AI 辅助文献筛选的研究设计

文献更快排到前面以后，怎样知道关键证据没有漏掉？

贯穿案例：主动学习辅助题名与摘要筛选
讨论对象：研究问题、比较设计、停止规则与来源核对

基金申报中的研究论证与 AI 辅助核查

基金申请中的 AI 使用规定

8. 申请人在撰写科学基金项目申请书时，如果借助生成式人工智能技术跟踪研究动态、收集整理参考文献，必须由人工核实生成式人工智能生成信息和参考文献的真实性和准确性。申请人应当对使用的生成内容负责，应当全面如实声明使用情况，并按照国家有关规定对相关内容进行标识。不得使用由生成式人工智能直接生成的申请书，不得使用未经核实的生成内容。

材料整理与核实	借助 AI 跟踪动态、整理参考文献后，申请人仍须逐项核实真实性与准确性，并如实声明使用情况。
本节课的操作范围	读取公开规定，核对来源，检查研究设计。研究者本人形成学术判断与申请书正文。
Word 文件的用途	把已确认的材料整理成研究设计工作底稿。不得将 AI 直接生成的申请书用于申报。

来源： 2026 年度国家自然科学基金项目指南，申请规定第 16 页

2026 年正文结构与研究论证

01	**立项依据**	已有方法解决到哪里？ 本研究还需要回答什么？	辅助排序在何种情境下会漏检，是否有可检验的解释。
02	**研究内容**	通过哪些比较和观测 回答这个问题？	固定参考集、对照方法与停止规则，评价召回和筛选量。
03	**研究基础**	哪些前期工作能够 支撑这项设计？	如实提供可用数据、标注经验和代码；缺失条件列入风险。

面上项目、青年科学基金项目（C 类）正文调整为三部分，篇幅原则上不超过 30 页。研究内容可依研究逻辑自主组织。

来源：国家自然科学基金委《关注！！！ 2026 年申请书改版》， 2025-12-30

“提高筛选效率”还缺少哪些条件

原稿

本项目拟构建智能文献筛选系统，①显著提升筛选效率，②保证筛选准确性，③形成可推广的方法，④为科研工作提供有力支撑。

① 与谁相比

人工顺序筛选，还是
已有主动学习方法?

② 怎样算准确

漏掉了多少相关研究?
分母是什么?

③ 推广到哪里

哪个学科？摘要是否完整?
任务难度是否相同?

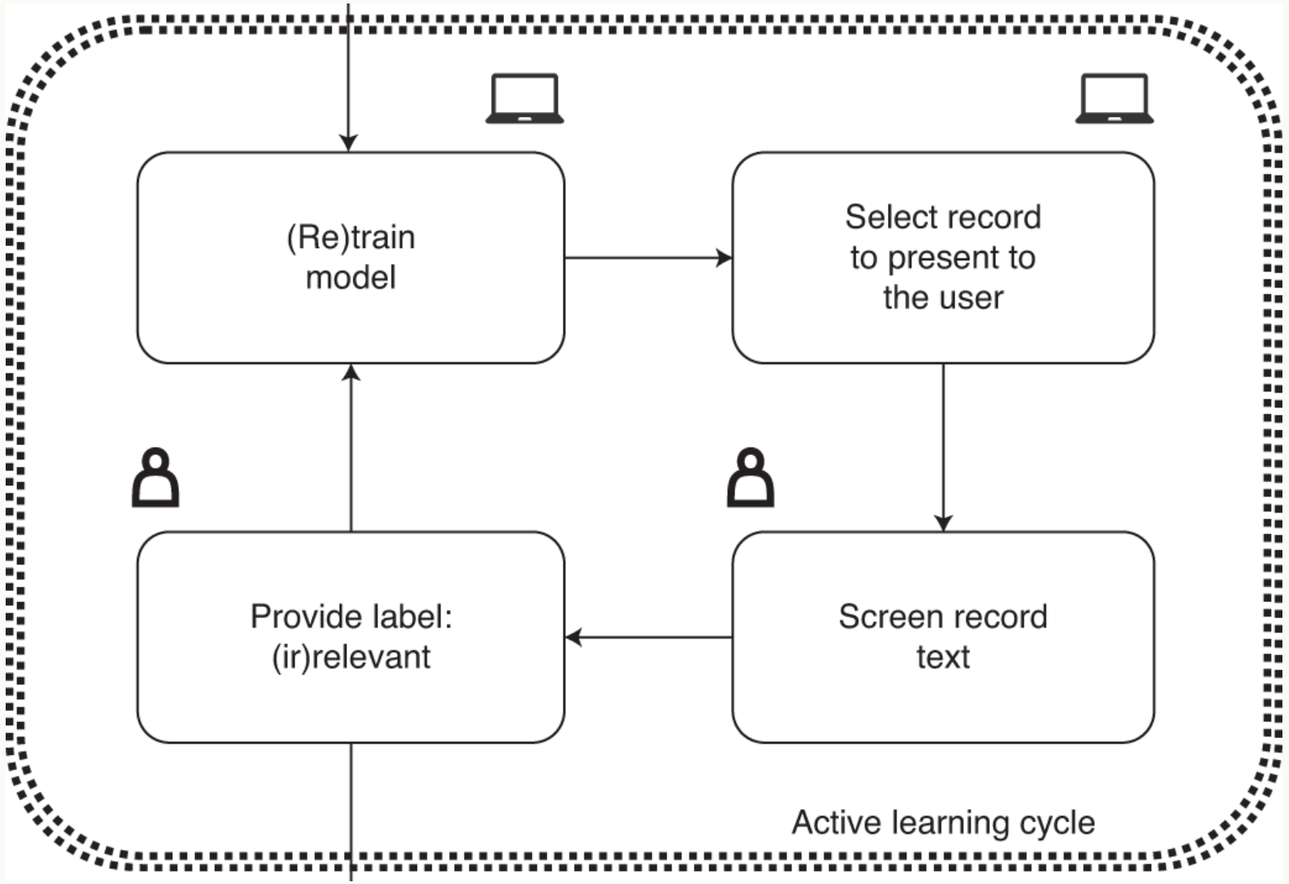
④ 产出如何检验

使用什么输入?
谁能重复得到哪些结果?

可检验的表述：在具有独立纳入标签的文献集合上，比较固定停止规则下的召回率与筛选量，并按主题和摘要完整度分析漏检记录。

ASReview 的人工反馈循环

人工判读与标签反馈（原图局部）



模型决定下一条先看什么

软件根据既有标签更新排序，呈现下一条记录。筛选者作出相关性判断。

停止时仍可能有未判读记录

停止后，剩余记录仍无真实标签。低优先级不能直接等同于“不相关”。

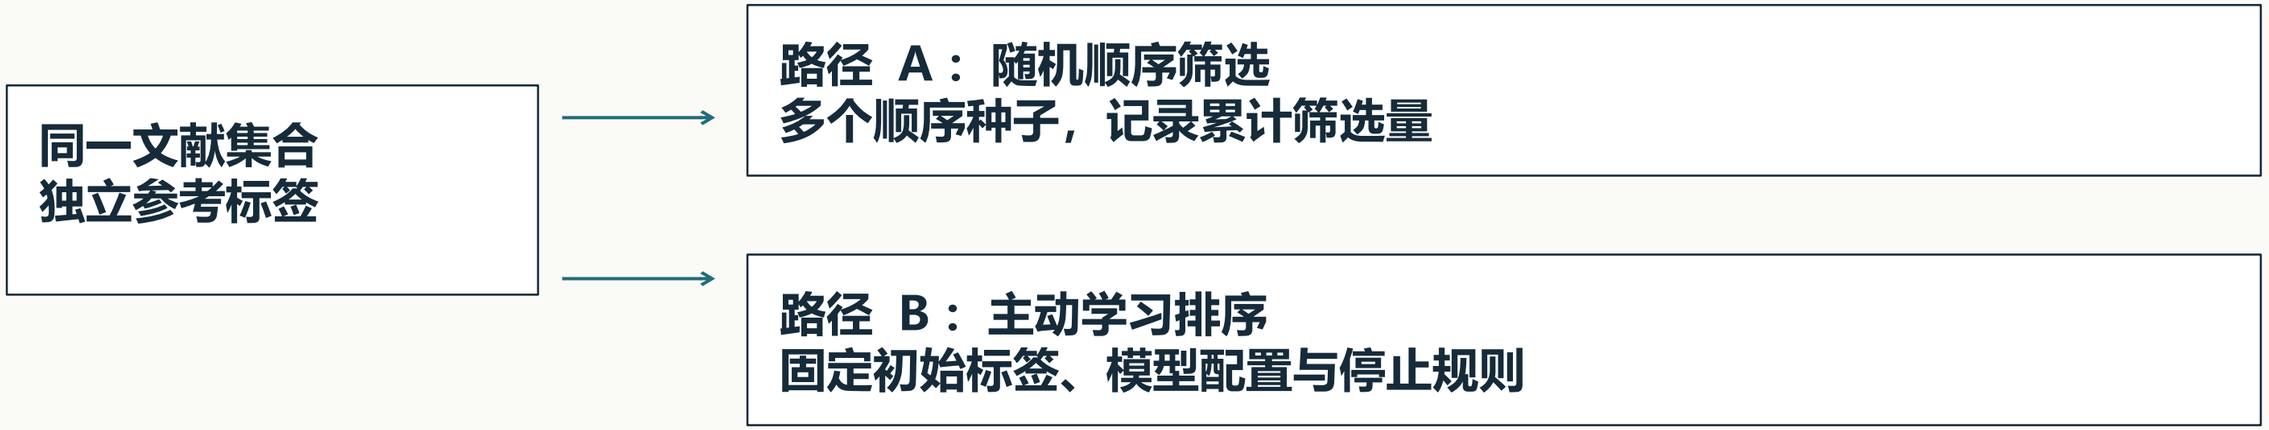
由此提出的课堂研究问题

初始样本与待筛文献的主题差异，是否影响早停时的漏检分布？需要在独立数据上检验。

van de Schoot et al. (2021), Fig. 1. DOI: 10.1038/s42256-020-00287-7. CC BY 4.0

比较设计：同一参考集，两条筛选路径

独立参考集包含每条记录的纳入判定。运行时，系统只能看到已筛记录的标签。



离线评价：各自到达预定召回水平时，需要筛选多少记录？

1. 同一集合配对比较，完整记录每次随机种子。
2. 评估脚本读取参考标签，排序引擎不得提前访问。
3. 新增模型或调参使用开发集，最终测试集独立保留。

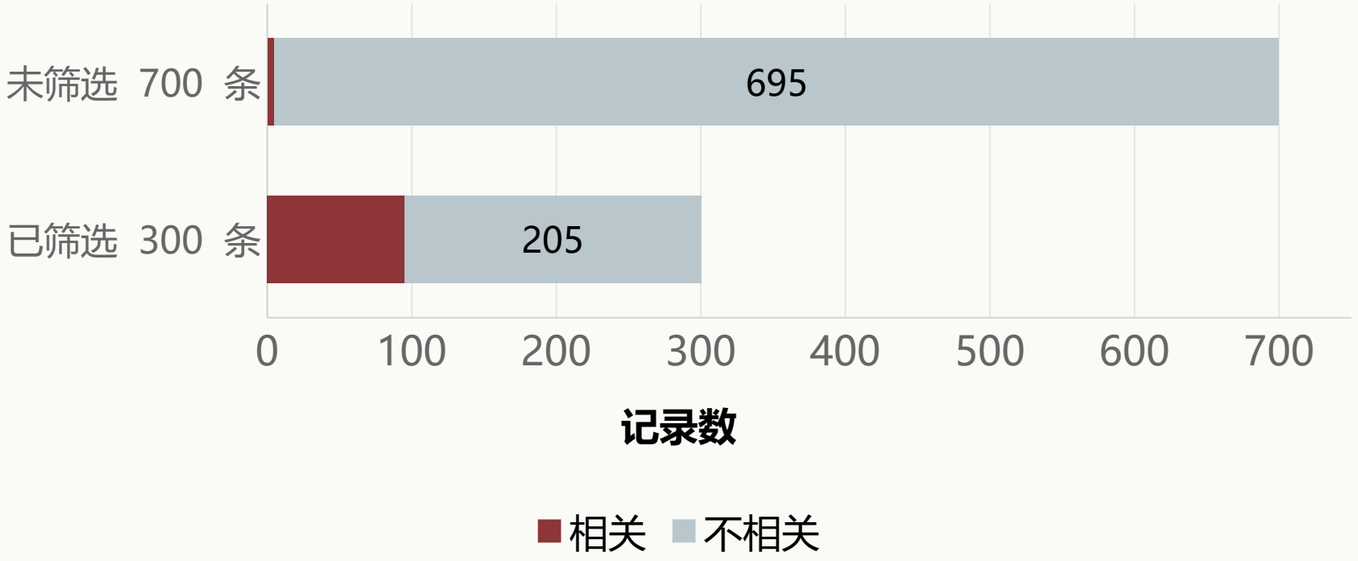
研究目标、观测量与结论范围

评价问题	怎样观测	解释所需条件
筛选工作量	达到预定召回时的已筛条数 ÷ 总条数	预先给出召回目标；记录未达目标的运行。
漏检风险	停止时尚未找出的相关记录数	报告分母、参考标签来源及漏检主题。
条件差异	初始样本、主题构成、摘要缺失情况	每次只改变计划中的因素，保留配置与种子。
可重复性	输入快照、代码版本和逐条判读日志	由独立人员复跑，核对记录序列与统计结果。

课堂设计暂取 95% 为评价点。这个数值是教学假设，须由真实任务的风险和用途论证。

召回率与筛选量的课堂算例

假设共 1,000 条记录，独立参考标签中有 100 条相关。停止时已筛 300 条，其中 95 条相关。



召回率

95 ÷ 100 = 95%

已筛记录中的相关比例

95 ÷ 300 ≈ 31.7%

筛选比例

300 ÷ 1,000 = 30%

尚未找出的相关记录

100 − 95 = 5 条

相关记录：已筛 95 条，未筛 5 条（教学设定）

算例中的未筛 700 条仍含 5 条相关记录。减少 70% 的筛选条数，不等于已经实测节约 70% 的总工时。

停止规则与未知的漏检量

离线回放：参考答案已知

独立评价脚本能够计算每一步的召回率，并比较不同规则的结果。

如果利用测试集的完整答案来决定真实筛选何时停止，就引入了答案信息。

实际使用：相关总数未知

“连续若干条未发现相关”只能描述最近的观察，不能直接证明剩余集合没有相关研究。

停止规则及未筛集合的复核办法需要预先说明，再用独立数据评价。

讨论：连续 50 条均不相关，能否据此声称“召回率达到 95%”？还缺哪些信息?

技术路线中的输入、判断与输出

01

资料与标准

公开数据和许可核查
制定纳入标准、独立标注

交付：数据字典、标签与分歧记录

02

冻结与比较

划分开发集和测试集
固定模型、种子及停止规则

交付：配置文件与逐条筛选日志

03

评价与解释

复算召回和筛选量
核对漏检主题及标签争议

交付：统计脚本、图表与限制说明

研究者负责：纳入标准、争议仲裁、风险判断与结论

程序负责：读取授权输入、按配置运行、保存记录与复算

课堂研究设计案例，无实测结果

证据怎样支撑研究者的论述

已知事实	ASReview 将人工判读纳入主动学习循环，依据反馈调整记录的呈现顺序。该文提供软件与复现实验资源。
拟研究的问题	本课堂方案关注初始样本的主题覆盖与停止时漏检分布的关系，拟在独立标注集合上作配对比较。
尚待补齐的依据	相关停止策略与跨主题评估文献是否已有相同设计？数据集是否适合本问题？这些问题须查证后再谈创新性。

第一段有文献依据；第二段是拟议设计；第三段列出查新与可行性缺口。三种证据状态分别表述。

方法依据： van de Schoot et al. (2021) 。研究问题与方案为课堂示例，尚未实验或完成查新。

研究设计工作底稿的核对



AI 辅助文献筛选研究设计工作底稿

课程讨论用　2026 年 10 月 17 日

本底稿采用拟议研究和教学算例，含 AI 辅助编写，尚未实施实验或完成查新。它用于检查研究设计，不是基金申请书。学员应以本人研究材料填写并承担学术判断。

研究问题

初始相关样本的主题覆盖，是否改变主动学习早停时的漏检分布？数据集是否适合检验这一问题、同类研究是否已完成该比较，均待查证。

资料与参考标签

拟使用有许可的公开题名与摘要数据。依据预先确定的纳入标准，由独立筛选者标注并仲裁分歧。记录数据来源、许可、纳入标准、标签版本及缺失情况。当前尚未选定实际数据集。

比较与信息隔离

同一集合比较随机顺序与主动学习排序。预先固定初始标签、模型配置及停止规则，保留随机种子。评价脚本使用完整参考标签；排序引擎只读取已经揭示的标签。调参与最终测试使用不同集合。

评价与解释

拟报告预定召回水平下的筛选比例，以及停止时的漏检记录和主题。课堂暂用 95% 作为评价点，实际阈值须结合漏检后果论证。多次运行保留变异；人工阅读与计算耗时分别记录。

算例与分母

教学设定：总计 1,000 条，相关 100 条；已筛 300 条，找出相关 95 条。召回率 95%，已筛记录中的相关比例约 31.7%，筛选比例 30%，尚漏 5 条。该算例不代表实验结果或已节约的工时。

来源与待补条件

方法背景：van de Schoot 等，Nature Machine Intelligence 3，125–133（2021），DOI 10.1038/s42256-020-00287-7。下一步须补充停止规则和跨主题评价文献、数据许可与标注成本，再决定研究是否可行。

核对记录：研究者、核对日期、资料版本与未解决问题应随真实任务填写。不得填入不存在的研究基础或成果。

问题能否回答

比较对象、目标召回和停止条件是否明确。

数据能否取得

许可、参考标签、标注分歧与开发测试划分是否落实。

推理是否成立

筛选比例、召回率和工时是否混用，有无答案泄漏。

文字是否有依据

逐句区分公开事实、研究假设与计划，不填写不存在的前期成果。

课堂任务：用自己的一个研究题目填写工作底稿。先补齐设计条件，再决定是否需要 AI 协助整理。